



Aplicación de Modelos de ML para lograr predecir el rendimientos de Arándanos Silvestres

- Mayumy Carrasco Huaccha -



- Mayumy Carrasco Huaccha -

Lic. Scientific Computing || Datalover
Analytic Projections in Camposol



[MayumyCH](#)




[MayumyCH](#)



[Mayumy Carrasco Huaccha](#)

"Nunca te rindas, lo que es hoy es difícil, mañana es una conquista" 🦴 🐼





01.

Comprensión del Negocio y los datos

El desafío mas grande que se tiene en el sector de la agricultura es lograr ***predecir el rendimiento de los cultivos.***





Obtención y carga de la data

Kaggle – Artículo “*Wild blueberry yield prediction using a combination of computer simulation and machine learning algorithms*”

	clonesize	honeyBee	bumblesBee	andrenaBee	osmiaBee	MaxTempBS	MinTempBS	AverageTempBS	MaxTempBI	MinTempBI	AverageTempBI	RainingDays	AverageRainingDays	fruitset	fruitmass	seeds	yield
0	37.5	0.75	0.25	0.25	0.25	86.0	52.0	71.9	62.0	30.0	50.8	16.0	0.26	0.410652	0.408159	31.678898	3813.165795
1	37.5	0.75	0.25	0.25	0.25	86.0	52.0	71.9	62.0	30.0	50.8	1.0	0.10	0.444254	0.425458	33.449385	4947.605663
2	37.5	0.75	0.25	0.25	0.25	94.6	57.2	79.0	68.2	33.0	55.9	16.0	0.26	0.383787	0.399172	30.546306	3866.798965
3	37.5	0.75	0.25	0.25	0.25	94.6	57.2	79.0	68.2	33.0	55.9	1.0	0.10	0.407564	0.408789	31.562586	4303.943030
4	37.5	0.75	0.25	0.25	0.25	86.0	52.0	71.9	62.0	30.0	50.8	24.0	0.39	0.354413	0.382703	28.873714	3436.493543
5	37.5	0.75	0.25	0.25	0.25	86.0	52.0	71.9	62.0	30.0	50.8	34.0	0.56	0.309669	0.366284	27.345454	2825.003738
6	37.5	0.75	0.25	0.25	0.25	94.6	57.2	79.0	68.2	33.0	55.9	24.0	0.39	0.284443	0.352186	26.101179	2625.269164
7	37.5	0.75	0.25	0.25	0.25	94.6	57.2	79.0	68.2	33.0	55.9	34.0	0.56	0.246568	0.342826	25.042361	2379.905214



777 registros / 17 columnas






02.

EDA y Preparación de la data



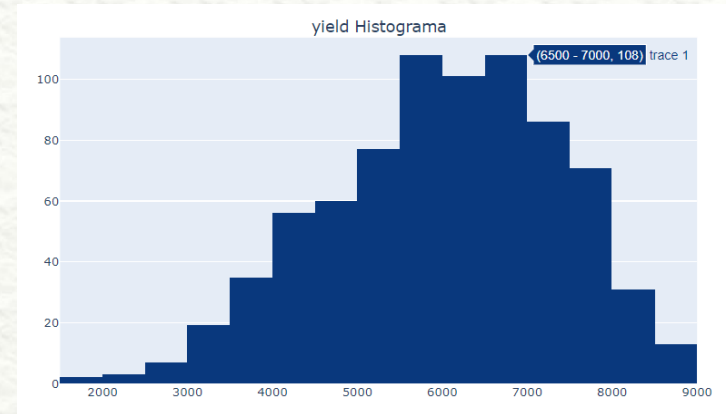


Variable target: “Yield”




50%


Del rendimiento obtenido
esta entre 5115 y 7022
kilos/Ha.



Análisis de correlación




Se observa que hay **features** que sean **correlacionados entre sí**:
Ejemplo: Clima de las banda superior e inferior y features del fruto.



Variables Predictoras



	fruitset	RainingDays	AverageTempBS	osmiaBee	bumblesBee	andrenaBee	honeyBee	clonesize
0	0.410652	16.0	71.9	0.25	0.25	0.25	0.75	37.5
1	0.444254	1.0	71.9	0.25	0.25	0.25	0.75	37.5
2	0.383787	16.0	79.0	0.25	0.25	0.25	0.75	37.5
3	0.407564	1.0	79.0	0.25	0.25	0.25	0.75	37.5
4	0.354413	24.0	71.9	0.25	0.25	0.25	0.75	37.5
5	0.309669	34.0	71.9	0.25	0.25	0.25	0.75	37.5



.98

fruitset

-.54

RainingDays

-.18

AverageTempBS

.38

osmiaBee

.31

bumblesBee

.14


andrenaBee

-.04

honeyBee


-.52

clonesize



Eliminar los outliers de nuestra data

```
df_blueberry = df_blueberry[~((df_blueberry < (q1 - 1.5 * iqr)) |(df_blueberry > (q3 + 1.5 * iqr))).any(axis=1)]
```



752 registros / 9 columnas





03.

Modelamiento y Evaluación





Datos de Entrenamiento y Test

```
# Separar Variables
X = df_blueberry.drop(columns="yield") # Variables predictoras
y = df_blueberry["yield"] # Variables Target o Objetivo

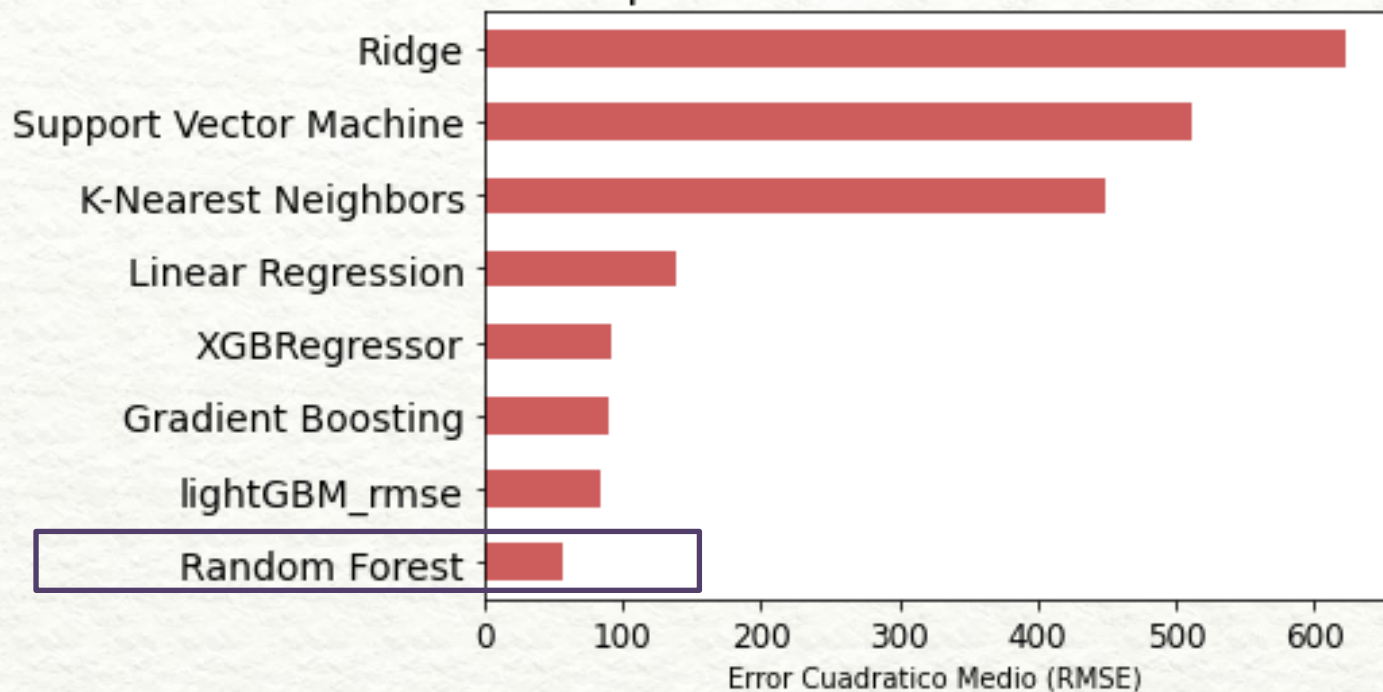
X_train, X_test, y_train, y_test = train_test_split(X, y,
                                                    test_size=0.3, random_state=88)
```

```
print("Tamaño del X_train",X_train.shape, "\nTamaño del X_test ",X_test.shape)
print("--")
print("Tamaño del y_train",y_train.shape, "\nTamaño del y_test ",y_test.shape)
```

```
Tamaño del X_train (526, 8)
Tamaño del X_test  (226, 8)
--
Tamaño del y_train (526,)
Tamaño del y_test  (226,)
```



Comparando los modelos con métrica RMSE





Modelo escogido

```
# Los mejores parametros:  
random_forest_regresor = RandomForestRegressor(random_state=0,n_estimators=200,max_depth=10)  
random_forest_rmse = fit_and_evaluate(random_forest_regresor,True)  
  
model_pred_train = random_forest_regresor.predict(X_train)  
model_pred_test = random_forest_regresor.predict(X_test)
```

Calculando los errores en la data del TRAIN


```
-----  
Linear Regression Performance on the test set: MAE = 45.59  
Linear Regression Performance on the test set: MSE = 3349.45  
Linear Regression Performance on the test set: RMSE = 57.87  
r2_square= 1.00
```

Calculando los errores en la data del TEST

```
-----  
Linear Regression Performance on the test set: MAE = 116.42  
Linear Regression Performance on the test set: MSE = 21264.28  
Linear Regression Performance on the test set: RMSE = 145.82  
r2_square= 0.99
```



Importancia de los features

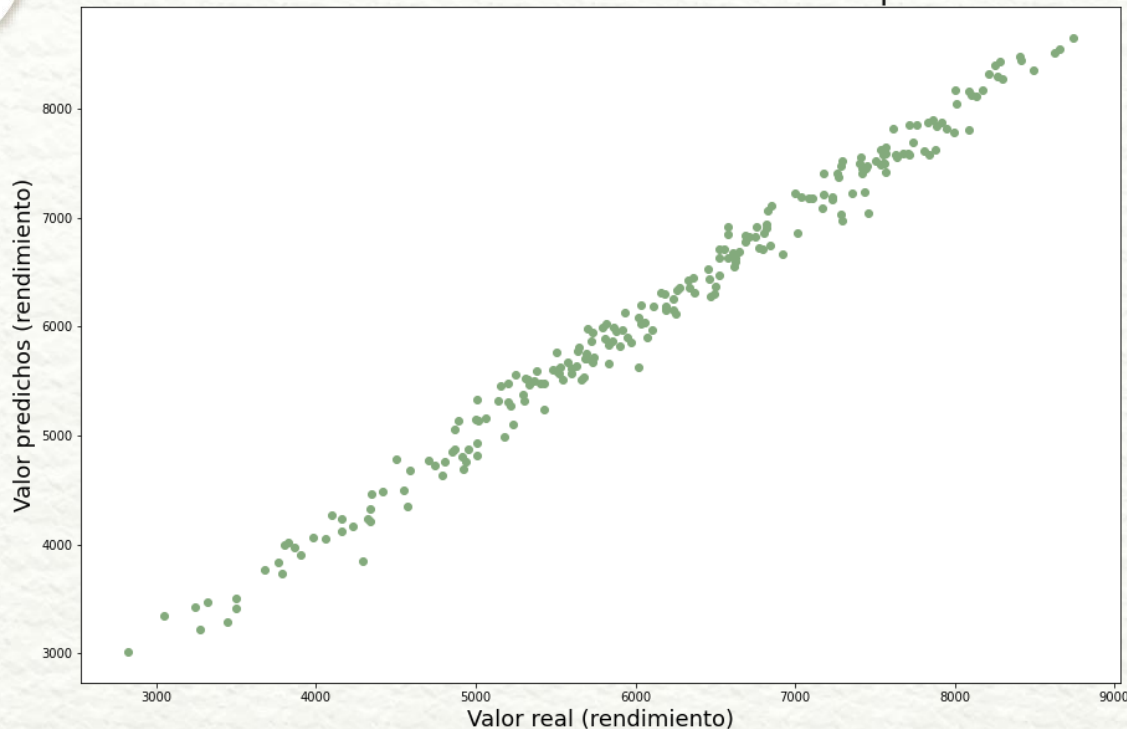


El feature *fruitset* es el que tiene mas importancia.



Modelo escogido

Valor del rendimiento real vs el rendimiento predicho



El modelo predice
con un error de
 ± 57.10 kilos/ha
(rendimiento de los
arándanos silvestres)





04.

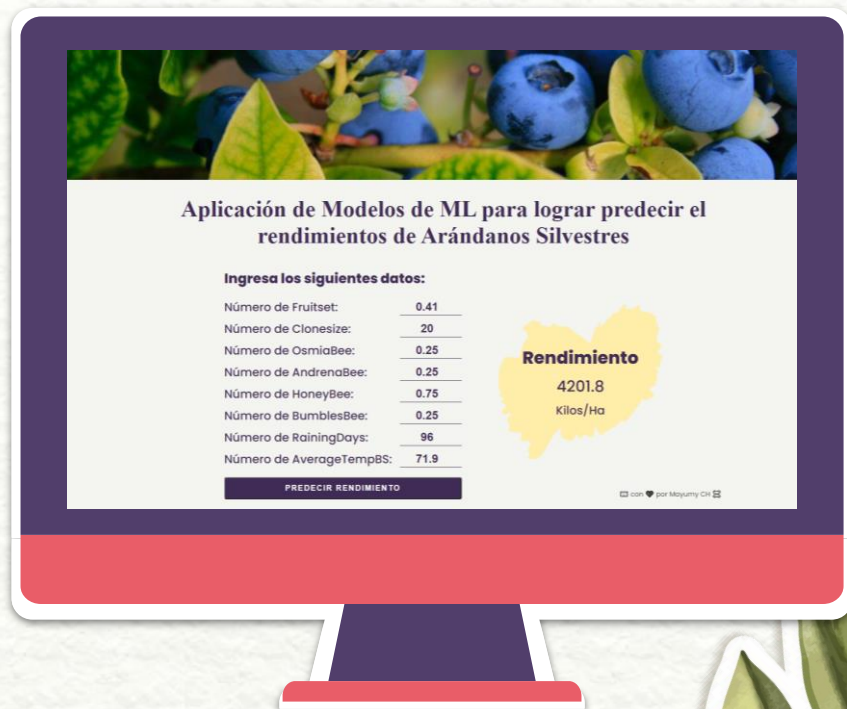
Despliegue





DEMO del Modelo

- Api creado con **FastApi** para consumir el modelo.
- Frontend con **Angular** para correr el modelo



Gracias totales

Agradecimiento especial
Bootcamp de Código Facilito

